

Universidad de Buenos Aires
Facultad de Ciencias Económicas

Tecnicatura Universitaria en Gestión y Análisis de Datos en Organizaciones

Laboratorio de Métodos Cuantitativos Aplicados a la Gestión

¿Quién habla en Springfield?

Protagonismo de los personajes y valoración de los episodios de *Los Simpson* (1989-2016)

Integrante	**N.º de registro**	**GitHub**
Bautista Cortés	922142	@bauti0727
Gabriel Goldadler	922212	@ggoldadler-blip
José Luis Joannás	922214	@PAKETTE
Naomi Asato	922221	@enedenao
		@dagut-rrd

Repositorio: `https://github.com/enedenao/tp_labo`

2do Cuatrimestre 2026
6 de noviembre de 2026

Resumen

Se analiza si el protagonismo de la familia Simpson se asocia con la valoración de los episodios en IMDb y si esa relación se mantiene en el tiempo. Con el dataset de Todd Schneider (564 episodios con guion, 1989–2016), el protagonismo se midió como el porcentaje de palabras dichas por Homero, Marge, Bart y Lisa en cada episodio y se correlacionó con el *rating* en tres períodos. Los cuatro concentran casi la mitad del diálogo (46,8 %), con Homero a la cabeza (21,0 %). No hay asociación general entre protagonismo y valoración ($r = 0{,}01$; $p = 0{,}80$), y solo en 2010–2016 aparece una asociación débil y positiva ($r = 0{,}24$). El *rating* cayó de 8,07 a 6,79 entre el primer y el último período, sobre todo en las temporadas 9 a 11, mientras el protagonismo se mantuvo.

1. Introducción

Los Simpson es una de las series de animación más extensas de la televisión, con un elenco que combina una familia central y cientos de personajes secundarios. Esta estructura plantea una pregunta relevante para la producción de contenido: cuánto peso narrativo conviene darle al elenco principal frente al resto de los personajes.

El presente trabajo analiza los guiones y la valoración de los episodios emitidos entre 1989 y 2016 para responder la siguiente pregunta:

> *¿Qué personajes concentran el diálogo en Los Simpson, y existe una asociación entre el protagonismo de los personajes principales y la valoración de los episodios en IMDb que se mantenga a lo largo de las décadas?*

Los datos provienen del conjunto *The Simpsons by the Data*, recopilado por Todd Schneider y publicado en Kaggle.

2. Datos y metodología

2.1. Datos

Se utilizan dos tablas del dataset. La tabla de episodios contiene 600 episodios de 28 temporadas, emitidos entre el 17/12/1989 y el 16/10/2016, con su temporada, fecha de emisión, audiencia en Estados Unidos y calificación en IMDb. La tabla de diálogos contiene una fila por cada línea del guion, con el episodio, el personaje que habla y la cantidad de palabras.

La exploración inicial detectó varios problemas de calidad que condicionaron el análisis:

- El archivo de diálogos contiene 23 filas mal formadas (sobre 158.271), que se descartaron al cargarlo.
- El archivo mezcla diálogos con acotaciones del guion (26.158 líneas que describen escenas) y contiene una fila corrupta; ninguna de ellas se considera.
- 36 episodios no tienen guion en el dataset; 33 de ellos pertenecen al período 2010-2016.
- La temporada 28 solo tiene 4 episodios, porque los datos se recopilaron poco después de su estreno.

2.2. Transformaciones

- Se conservaron solo las 132.089 líneas habladas, se descartaron 2 sin personaje asignado y se identificó a cada personaje por su código (`character_id`), que unifica las variantes de nombre (por ejemplo, “Young Homer” y “Homer Simpson”).

- Se midió el **protagonismo** de cada episodio como el porcentaje de sus palabras dichas por los cuatro personajes con más diálogo (Homero, Marge, Bart y Lisa).
- Se distinguen dos medidas: la **concentración del diálogo** (Tabla 1) es el porcentaje del total de palabras de un período dicho por cada personaje, mientras que el **protagonismo promedio** (Tabla 2) promedia el porcentaje de cada episodio, de modo que todos pesan igual. Por eso sus valores difieren levemente.
- Se convirtió la fecha de emisión y se agruparon los episodios en tres períodos: 1989-1999, 2000-2009 y 2010-2016.
- La base final de análisis quedó en 564 episodios con guion y calificación.

2.3. Herramientas

El análisis se realizó en Python (Google Colab) con las bibliotecas `pandas`, `numpy`, `matplotlib`, `seaborn` y `scipy`. La asociación se midió con los coeficientes de correlación de Pearson, con su prueba de hipótesis ($H_0 : \rho = 0$), para el total y para cada período.

3. Resultados

3.1. ¿Quién concentra el diálogo?

En toda la serie, Homero dice cerca del 21 % de las palabras, y los cuatro personajes principales juntos, el 46,8 %: casi la mitad del diálogo se concentra en cuatro personajes, de más de 6.000 nombres distintos. Este reparto se mantiene estable en los tres períodos (Tabla 1 y Figura 1).

Tabla 1: Porcentaje de las palabras de cada período dichas por los personajes principales y por el resto de los personajes.

Período	Homero	Marge	Bart	Lisa	Total 4 principales	Resto
1989–1999	21,2	9,3	9,1	7,3	46,9	53,1
2000–2009	21,2	10,4	7,8	7,9	47,3	52,7
2010–2016	19,9	9,0	8,5	8,2	45,6	54,4

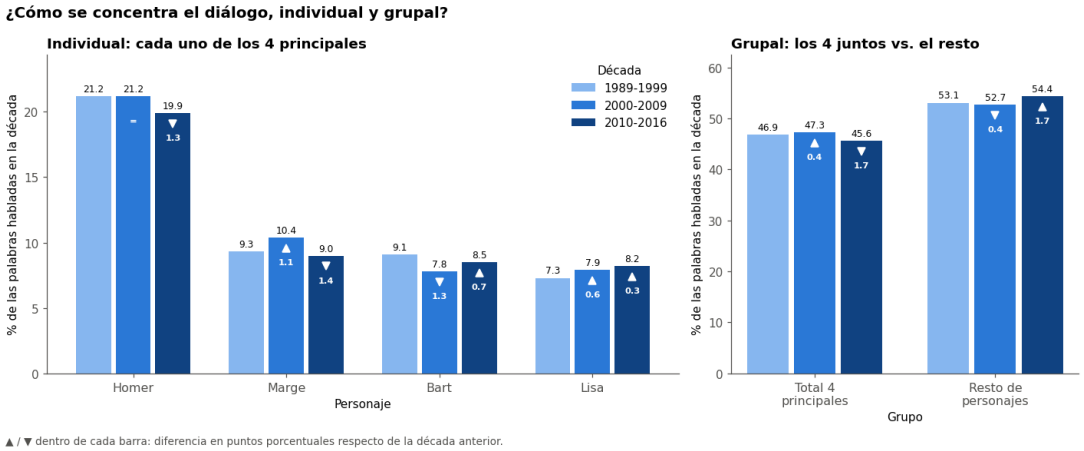


Figura 1: ¿Quién concentra el diálogo? A la izquierda, el porcentaje de las palabras de cada período dichas por cada uno de los cuatro principales; a la derecha, los cuatro juntos frente al resto de los personajes. Los triángulos indican cuánto subió (▲) o bajó (▼) cada valor respecto del período anterior.

La familia sostiene casi la mitad del diálogo en las tres décadas (entre 45,6 % y 47,3 %), y ese protagonismo se apoya en un solo personaje: Homero concentra entre 43,6 % y 45,2 % de lo que dice el grupo familiar, más del doble que cualquiera de los otros tres. La leve caída de 2010–2016 (1,7 puntos) la explican Homero (−1,3) y Marge (−1,4), compensados en parte por Bart (+0,7) y Lisa (+0,3). Medido dentro de la familia, el reparto se reacomoda lentamente: Homero cede peso (45,2 %, 44,8 % y 43,6 %) y Lisa lo gana (15,6 %, 16,7 % y 18,0 %), las únicas dos tendencias sostenidas, mientras Marge y Bart alternan subas y bajas sin una dirección clara.

3.2. Protagonismo y valoración en el tiempo

El protagonismo promedio casi no varió entre períodos (47,1 %, 47,3 % y 45,8 %), mientras que la calificación promedio cayó de 8,07 a 7,05 y a 6,79 (Tabla 2 y Figura 2).

Tabla 2: Protagonismo y calificación en IMDb por período.

Período	Episodios	Protagonismo promedio (%)	*Rating* promedio
1989–1999	235	47,1	8,07
2000–2009	211	47,3	7,05
2010–2016	118	45,8	6,79

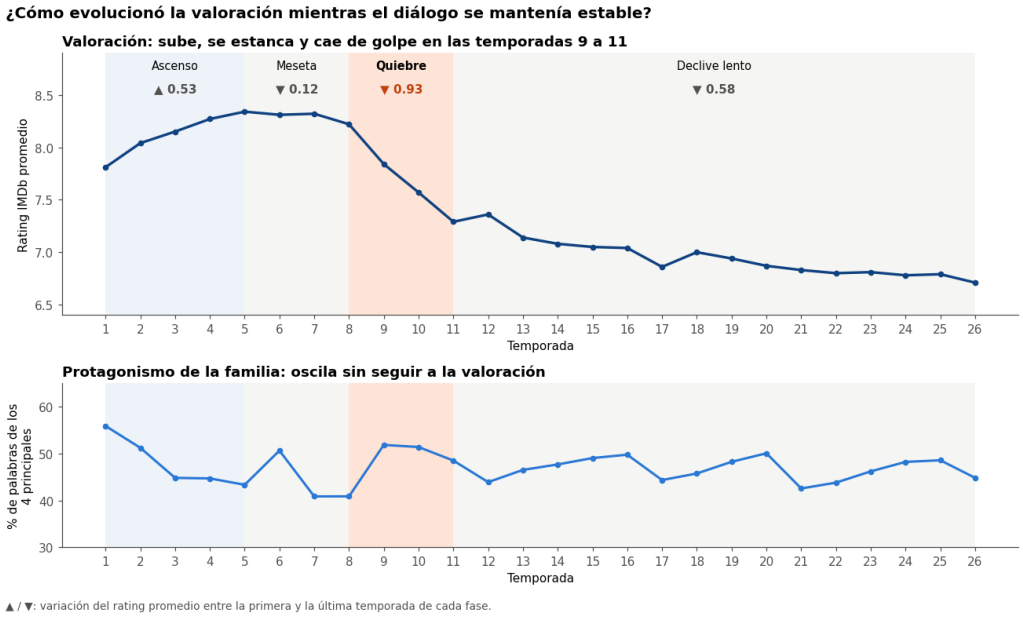


Figura 2: ¿Cómo evolucionó la valoración mientras el diálogo se mantenía estable? Arriba, el *rating* IMDb promedio por temporada; abajo, el porcentaje de palabras dichas por los cuatro principales. Las zonas marcan cuatro fases: ascenso (temporadas 1 a 5), meseta (5 a 8), quiebre (8 a 11, con caídas en las temporadas 9, 10 y 11) y declive lento (11 a 26), con la variación del *rating* en cada una.

La valoración no cae de forma gradual. Entre el máximo de la temporada 5 (8,34) y la temporada 26 (6,71), el *rating* pierde 1,63 puntos, y 0,93 de ellos (el 57 %) se concentran en las temporadas 9 a 11, más que en las 15 temporadas siguientes juntas (0,58). Esas temporadas se emitieron entre septiembre de 1997 y mayo de 2000, justo en el límite entre las dos primeras décadas, por eso el promedio por período muestra un escalón (8,07 a 7,05) pero esconde que la caída ocurrió en un lapso tan corto. Durante el quiebre, la familia ganó protagonismo en lugar de perderlo: sus palabras pasan de 40,9 % en la temporada 8 a 51,9 % en la 9. El peso de la familia

no explica entonces la caída, aunque se trata de una coincidencia temporal y no de una relación causal.

3.3. Asociación entre protagonismo y valoración

En la serie completa no se encontró asociación entre protagonismo y calificación. Por período, la correlación fue negativa y débil en 1989–1999, nula en 2000–2009 y positiva y débil en 2010–2016 (Tabla 3). La relación negativa del primer período desaparece al comparar cada episodio solo con los de su misma temporada: era un efecto del calendario, ya que en las primeras temporadas el protagonismo bajaba mientras el *rating* subía. La del último período se mantiene y es la única distinta de cero (Figura 3).

Tabla 3: Correlación de Pearson entre protagonismo y calificación, con su p-valor, para cada período: sin control y comparando cada episodio solo con los de su misma temporada.

		Sin control		Dentro de temporada	
Período	Episodios	r	p	r	p
1989–1999	235	−0,12	0,056	−0,02	0,812
2000–2009	211	0,00	0,963	0,02	0,813
2010–2016	118	0,24	0,010	0,24	0,008
Toda la serie	564	0,01	0,799	0,06	0,182

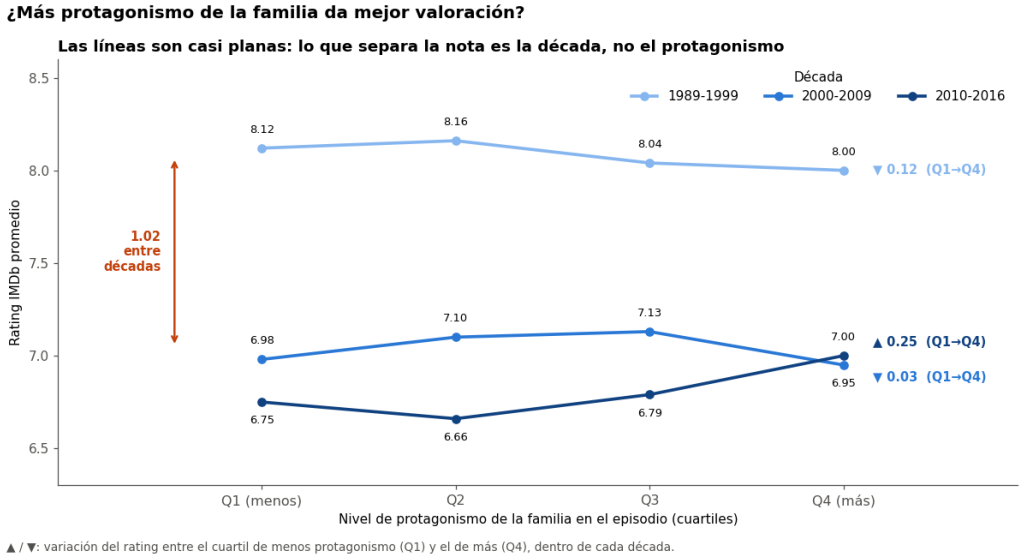


Figura 3: ¿Más protagonismo de la familia da mejor valoración? *Rating* IMDb promedio según el nivel de protagonismo del episodio (Q1: la familia habla menos; Q4: habla más), con una línea por período. Los triángulos indican cuánto sube o baja el *rating* de Q1 a Q4; la flecha de la izquierda marca la diferencia de *rating* promedio entre las dos primeras décadas.

Por personaje, Marge se asocia negativamente con la calificación en 1989–1999 ($r = -0{,}23$; $p = 0{,}0004$) y en 2000–2009 ($r = -0{,}20$; $p = 0{,}004$), también al comparar dentro de cada temporada. Homero muestra una asociación positiva y chica que solo aparece con ese control ($r = 0{,}16$ en toda la serie; $p = 0{,}0002$). Bart y Lisa no muestran relación. Los efectos individuales se compensan dentro del grupo, y son un patrón estadístico, no una explicación.

El protagonismo de la familia mueve poco la valoración dentro de cada década: entre el cuartil con mejor y peor *rating* la diferencia es de 0,16 puntos en 1989–1999, 0,18 en 2000–2009 y 0,34

en 2010–2016. El patrón tampoco se repite: baja levemente en la primera década (8,12 a 8,00), no sigue un orden en la segunda y sube en la tercera (6,75 a 7,00), donde además se apoya en menos episodios. La época de emisión pesa al menos tres veces más: el *rating* cae 1,02 puntos entre las dos primeras décadas, frente a un máximo de 0,34 dentro de una misma década, y esa distancia se corresponde en gran parte con el quiebre de las temporadas 9 a 11.

4. Conclusiones

El análisis respondió las dos partes de la pregunta. Primero, el diálogo se concentra en la familia: Homero, Marge, Bart y Lisa, de más de 6.000 personajes, dicen casi la mitad de las palabras (46,8 %), y ese reparto es estable entre 1989 y 2016 (entre 45,6 % y 47,3 % en cada período). Dentro del grupo, Homero concentra entre 43,6 % y 45,2 % de lo que dice la familia, más del doble que cualquiera de los otros tres, aunque cede peso lentamente a favor de Lisa.

Segundo, el protagonismo de la familia no está asociado de manera general con la valoración de los episodios ($r = 0{,}01$; $p = 0{,}80$), y esa falta de asociación no se mantiene igual en todas las décadas: es nula en 2000–2009, la correlación negativa de 1989–1999 desaparece al comparar episodios de una misma temporada, y solo en 2010–2016 aparece una asociación positiva y débil ($r = 0{,}24$; $p = 0{,}010$). Por personaje, los efectos son chicos y se compensan: Marge se asocia negativamente con la calificación en las dos primeras décadas y Homero positivamente, sin que eso permita afirmar que uno la baje y el otro la suba.

Lo que sí cambió fue la valoración, no el protagonismo. El *rating* promedio pasó de 8,07 a 7,05 y a 6,79, y 0,93 puntos de la caída desde el máximo (57 %) se concentran en las temporadas 9 a 11, durante las cuales la familia ganó protagonismo en lugar de perderlo. Lo que distingue la valoración de un episodio es en qué momento de la serie se emitió, más que cuánto habla la familia en él.

Limitaciones. La correlación no implica causalidad, y el conjunto de datos permite ver cuándo cayó la nota, no por qué. El protagonismo se mide solo por cantidad de palabras, lo que no captura la importancia de un personaje en la trama. El período 2010–2016 pierde el 22 % de sus episodios por falta de guion (33 de los 36 episodios sin guion), sin que pueda asegurarse que esa falta sea aleatoria, por lo que su resultado se apoya en menos datos. Se realizaron muchas comparaciones (cuatro personajes por cuatro períodos) sin corrección por comparaciones múltiples, de modo que la asociación de 2010–2016 debe leerse como un indicio y no como una conclusión firme. Además, el *rating* de IMDb varía poco (la mitad de los episodios está entre 6,9 y 8,0), por lo que cualquier asociación posible es necesariamente chica, y refleja a los usuarios que eligen votar, no a una muestra representativa del público. Por último, los períodos no son iguales: 1989–1999 incluye 1989 y 2010–2016 abarca siete años.

Posibles extensiones. Incorporar la audiencia en Estados Unidos (`us_viewers_in_millions`), analizar a los personajes secundarios y explorar qué cambió en las temporadas 9 a 11.

5. Reflexión metodológica

El trabajo se dividió en cinco etapas, cada una a cargo de un integrante, sobre un notebook compartido en GitHub. Al cerrar cada etapa, su responsable informaba al grupo lo realizado y sus recomendaciones para la siguiente, y los hallazgos se debatían por mensajería y en clase; no hubo validación externa. El dataset inicial, oficial del Gobierno de la Ciudad, se reemplazó por *Los Simpson*, un tema más original y menos sensible.

Cada integrante usó Claude en forma individual, dentro de un proyecto con el mismo contexto, para proponer y corregir código, mejorar la redacción y aclarar conceptos; su uso quedó documentado en el notebook. También generó la base de este informe en LaTeX, herramienta nueva para el grupo, y la del sitio web; la presentación partió de una plantilla de la IA de Canva. En todos los casos el grupo revisó y completó el contenido, y las cifras del informe se contrastaron

con el notebook. El mayor desafío fue organizarse en los plazos mientras se aprendían herramientas nuevas: la IA facilitó mucho el proceso, aunque queda mucho por aprender. Como primer trabajo grupal de análisis de datos, fue una experiencia muy valiosa.

Bibliografía

- Cátedra de Laboratorio de Métodos Cuantitativos Aplicados a la Gestión (2026). *Material de clase: notebooks de Google Colab*. Facultad de Ciencias Económicas, Universidad de Buenos Aires.
- sujanjoejacob (s.f.). *Text-mining-with-Simpsons-Data* [Repositorio de GitHub]. `https://github.com/sujanjoejacob/Text-mining-with-Simpsons-Data`